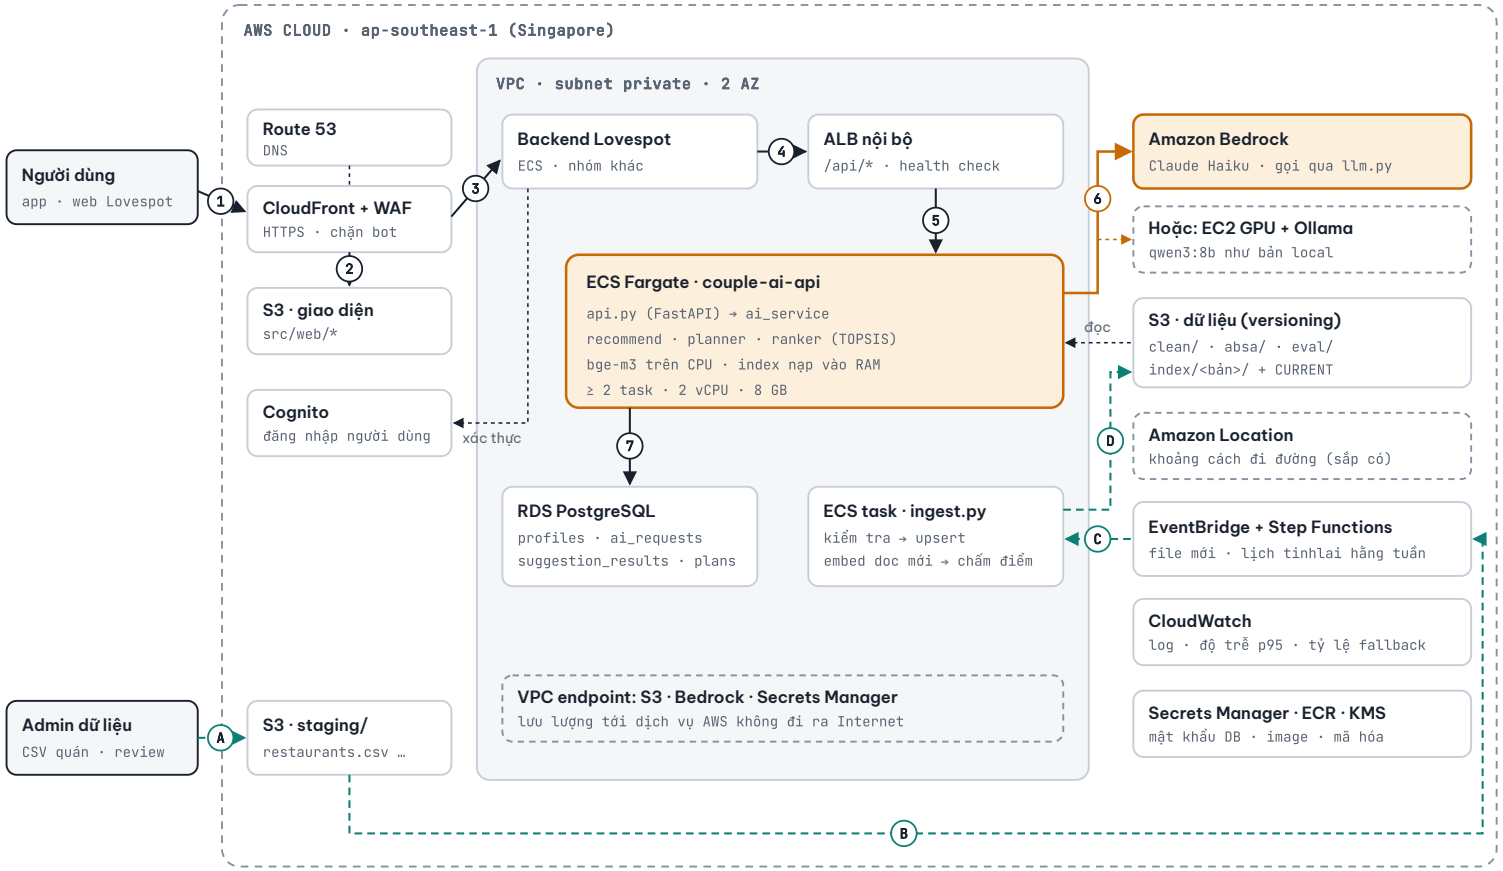
LOVESPOT · MODULE AI · AP-SOUTHEAST-1

Couple Assistant trên AWS

Kiến trúc đề xuất để đưa module AI gợi ý quán hẹn hò từ máy local (Windows, Ollama, file CSV) lên AWS. Mỗi khối trên sơ đồ ứng với một phần code đang chạy được: `src/api.py`, `ingest.py`, `llm.py`, index embedding có con trỏ `CURRENT`, hồ sơ và nhật ký AI.

Đề xuất · chưa triển khai



Dịch vụ AI chỉ nằm trong subnet private: người dùng không gọi thẳng vào nó, mà đi qua backend Lovespot (đã đăng nhập bằng Cognito). Bước 6 là chỗ duy nhất gọi LLM; đổi giữa Bedrock và GPU tự chạy chỉ cần sửa `llm.py`. Mọi task ECS đều đẩy log sang CloudWatch.

Luồng một yêu cầu gợi ý (1–7) — Bước gọi AI — Luồng nhập quán mới (A–D) — Phương án thay thế / sắp có

Một yêu cầu gợi ý đi qua đâu

1. Người dùng mở app, tên miền trỏ qua Route 53 tới CloudFront; WAF chặn bot và spam.
2. Trang tĩnh (giao diện `src/web`) phục vụ thẳng từ S3, không tốn máy chủ.
3. Lời gọi `/api` tới backend Lovespot; backend kiểm tra token Cognito.
4. Backend gọi ALB nội bộ: `POST /api/suggest` kèm mã hồ sơ hai người.
5. `couple-ai-api` kiểm tra lượt AI, lọc quận / ngân sách / giờ mở cửa, chấm điểm, giữ 15 quán. Index đã nạp sẵn trong RAM nên bước này dưới 1 giây.
6. Gửi 15 quán (không kèm tên hay mã người dùng) cho LLM chọn 3–5 quán và viết lý do. Code kiểm tra lại; LLM lỗi thì dùng thứ tự chấm điểm.
7. Ghi `ai_requests` và `ai_suggestion_results` vào RDS. Khi người dùng bấm chọn quán thì ghi `chosen_at`.

Khi nhập quán mới

- A. Admin tải `restaurants.csv` / `reviews.csv` lên `s3://…/staging/<đợt>/`.
- B. S3 phát sự kiện "file mới", EventBridge chuyển cho Step Functions.
- C. Step Functions chạy một task ECS với `ingest.py`: kiểm tra schema, hủy đợt nếu trên 30% dòng lỗi, upsert, chỉ embed doc mới.
- D. Task ghi bản index mới vào `index/<bản>/` rồi mới đổi `CURRENT`. Các task API thấy `CURRENT` đổi thì nạp bản mới; đang phục vụ vẫn dùng bản cũ nên không gián đoạn.

EventBridge Scheduler cũng chạy task `ingest.py --recompute` mỗi tuần để tính lại tham số Bayes và phân phối điểm.

Từ máy local lên AWS

ĐANG CHẠY Ở LOCAL	TRÊN AWS	LÝ DO CHỌN
`python run.py web` (FastAPI)	**ECS Fargate + ALB nội bộ**	Model bge-m3 khoảng 2,3 GB phải nạp sẵn trong RAM; Lambda khởi động lạnh quá chậm cho mỗi yêu cầu. Fargate không phải quản lý máy chủ.
Ollama + qwen3:8b	**Amazon Bedrock (Claude Haiku)**	Trả theo token, không phải nuôi GPU lúc rảnh. Code chỉ gọi LLM ở một hàm (`llm.ollama_json`), nên chỉ sửa một chỗ.

ĐANG CHẠY Ở LOCAL	TRÊN AWS	LÝ DO CHỌN
`data/clean`, `data/index` (numpy, con trỏ `CURRENT`)	**S3 có versioning**	Index chỉ khoảng 55 MB; giữ nguyên cơ chế "ghi bản mới rồi đổi con trỏ" đang có.
`data/profiles/*.json`, `data/ai_log/*.jsonl`	**RDS PostgreSQL + KMS**	Đã đặt tên trường theo bảng trong tài liệu Lovespot; dùng chung database với backend. Hồ sơ là dữ liệu cá nhân nên mã hóa bằng KMS.
`run.py nhap`, `run.py tinhlai`	**ECS task + EventBridge + Step Functions**	Chạy khi có file mới hoặc theo lịch, xong thì tắt; không tốn tiền lúc không có dữ liệu.
`src/web`	**S3 + CloudFront**	File tĩnh, không cần máy chủ.
Khoảng cách đường chim bay (`haversine_km`)	**Amazon Location Service**	Ứng với "Map Service" trong tài liệu; cần cho thời gian di chuyển giữa các chặng plan.
`run.py kiemtra`, `run.py danhgia`	**CodeBuild hoặc GitHub Actions**	Chạy 19 bài kiểm tra trước mỗi lần deploy; chặn deploy nếu có bài lỗi.

Ba điều cần chốt trước khi triển khai

LLM: Bedrock hay tự chạy GPU

Nên dùng Bedrock. Không phải quản lý GPU, và chỉ trả tiền khi có người hỏi. Dữ liệu gửi đi chỉ gồm sở thích dạng nhãn chung và thông tin quán.

Tự chạy Ollama trên EC2 GPU giữ y hệt bản local, nhưng phải trả tiền máy theo giờ kể cả lúc không ai dùng. Đổi model nào thì cũng phải chạy lại `run.py danhgia`, vì chất lượng chọn quán phụ thuộc model. Cần kiểm tra model định dùng có ở region Singapore không.

Index: giữ trong RAM hay chuyển sang vector database

Giữ index numpy trong RAM ở giai đoạn này. 853 quán và khoảng 22 nghìn doc tìm trong khoảng 30 ms, không cần thêm dịch vụ.

Chuyển sang RDS pgvector hoặc OpenSearch khi dữ liệu lên hàng trăm nghìn review, hoặc khi cần quán mới hiện ra ngay thay vì đợi đổi `CURRENT`.

Dữ liệu cá nhân và region

AWS chưa có region đầy đủ tại Việt Nam, nên đặt ở Singapore là chuyển dữ liệu ra nước ngoài. Theo Nghị định 13/2023, việc này cần hồ sơ đánh giá tác động. Cần bên pháp lý xác nhận trước khi lưu hồ sơ người dùng thật.

Phần code cần sửa để chạy trên AWS

- `llm.py` : thêm nhánh gọi Bedrock bên cạnh Ollama, chọn bằng biến môi trường.
- `ProfileStore` và `AiLog` : đọc / ghi bảng RDS thay vì file JSON / JSONL; giữ nguyên giao diện hàm.
- `config.py` : đọc đường dẫn S3 từ biến môi trường; khi khởi động tải bản index theo `CURRENT` , rồi kiểm tra lại định kỳ (ví dụ 5 phút).
- Thêm `Dockerfile` : image đã có sẵn model bge-m3 để task khởi động không phải tải lại.
- `/api/health` đã có sẵn, dùng làm health check cho ALB.

Sơ đồ này là đề xuất, chưa triển khai và chưa ước tính chi phí. Hiện hệ thống chạy local trên Windows với Ollama.